





Web Scraping Instagram avec <u>Selenium</u> et l'implémenation dans <u>Django</u>

Réalisé par : EL MAHFOUD RADOUANE

NOUALI TAHA

AMBAKANE DIT BREHIMA GUINDO

Encadré par : Kamal Idrissi

Filière: Data Engineer

2022-2023



Contents

1	Introduction					
	1.1 1.2	Web Scraping Outils Web Scraping	3 5			
2	Web	Scraping sous Selenium Python				
		La bibliothèque Selenium Documentation du Selenium	6 8			
3	Projet : Web Scraping Instagram avec Selenium					
	3.1	Démo sur les Scripts selenium	15			
	3.2	Implémentation web : django	19			





1. Web Scraping

Le web scraping (parfois appelé harvesting) est une technique d'extraction du contenu de sites Web, via un script ou un programme, dans le but de le transformer pour permettre son utilisation dans un autre contexte comme l'enrichissement de bases de données, le référencement ou l'exploration de données.

Le Web scraping sélectionne des textes sur les sites Internet afin d'obtenir des informations et de les enregistrer. Ce processus est comparable à un copier-coller automatique. Pour la recherche d'images, la dénomination du processus est encore plus précise et s'intitule image scraping.

Le scraping comprend différentes fonctionnalités, mais on opère généralement une distinction entre le scraping manuel et automatique. Le scraping manuel désigne le fait de copier et insérer manuellement des informations et des données. On peut le comparer avec le fait de découper et rassembler des articles de journaux. Le scraping manuel est uniquement effectué lorsque l'on souhaite trouver et enregistrer des informations de façon sporadique. Il s'agit d'un processus très laborieux qui est rarement appliqué pour de grandes quantités de données.

Dans le cas du scraping automatique, on utilise un logiciel ou un algorithme qui explore plusieurs sites Internet afin d'extraire des informations. Un logiciel spécifique est utilisé en fonction de la nature du site Internet et du contenu. Dans le scraping automatique, on distingue différentes méthodes :





- Les analyseurs syntaxiques : un analyseur syntaxique est utilisé pour convertir le texte en une nouvelle structure. Dans le cas de l'analyse d'un HTML par exemple, le logiciel lit le document HTML et enregistre les informations. L'analyse d'un DOM utilise l'affichage des contenus dans le navigateur côté client pour extraire les données.
- Les robots : un robot est un logiciel réalisant des tâches spécifiques et les automatisant. Dans le Web harvesting, les robots sont utilisés pour explorer automatiquement des sites Internet et collecter des données.
- Le texte : les personnes sachant utiliser la Command Line peuvent utiliser les instructions Unix grep pour explorer le Web à la recherche de certains termes dans Python ou Perl. Il s'agit d'une méthode très simple pour obtenir des données qui requiert toutefois davantage de travail que lorsqu'on utilise un logiciel.



2. Outils Web Scraping

Il existe de multiples frameworks et bibliothèques logicielles, certains reposent sur l'émulation d'une instance d'un navigateur web afin de réaliser des actions sur des pages web, d'autres frameworks et bibliothèques reposent sur l'analyse du code HTML de la page obtenu en réalisant une requête HTTP.

Les bibliothèques et frameworks les plus populaires pour le web scraping sont :

Nom	Langage		
Beautiful soup	Python		
Puppeteer	JavaScript (Node.js)		
Goutte	PHP (Symfony)		
Scrapy	Python		
Selenium	Multiples		
woob	Python		
PhantomJS	JavaScript		

L'utilisation d'interfaces de programmation est une bonne alternative aux bibliothèques et frameworks pour les développeurs souhaitant accélérer le développement de leurs applications de web scraping.

De nombreuses sociétés proposent des API de web scraping, généralement payantes, dont voici une liste non exhaustive des options les plus populaires :

- ScraperAPI
- ScrapingBee
- Scrapfly
- ScrapingFish
- Apify
- Bright Data
- Scraping bot
- Diffbot



1. La bibliothèque Selenium

Selenium est un framework développé en java, qui offre des passerelles pour s'exécuter avec différents langages comme Python et PHP. Il s'agit d'un outil puissant pour contrôler les navigateurs web grâce à des programmes et effectuer l'automatisation du navigateur. Il prend en compte tous les navigateurs, tous les principaux systèmes d'exploitation et ses scripts sont écrits dans différents langages comme Python, java, C# ...

Selenium vous permet de tester votre application web. En d'autres termes, il permet une automatisation efficace des tests de l'interface graphique des applications Web. Il est composé principalement de 4 composants à savoir : Selenium IDE, Selenium RC, Selenium Webdriver et Selenium GRID.

Selenium Python offre plusieurs avantages pour scraper les données d'un site web de façon structurée. L'apprendre est un grand atout si l'on souhaite effectuer du WebScraping. Les avantages de Selenium Python sont qu'il :

- est un framework open source et portable ;
- fonctionne avec de nombreux langages de programmation.
- peut être utilisé avec de nombreux navigateurs et plateformes différents.
- est alimenté par une grande communauté.
- peut explorer un site Web à l'aide d'un navigateur spécifique : bien que de nombreux logiciels de scraping



de sites Web utilise un véritable navigateur Web pour l'extraction de données, dans la plupart des cas, le navigateur qu'ils utilisent est WebBrowser Control, c'est-à-dire Internet Explorer. Selenium, cependant, fonctionne non seulement avec Internet Explorer, mais aussi avec une variété de navigateurs tels que Google Chrome, Firefox, Opera, HtmlUnit et même Android et iOS.

- peut extraire des pages Web complexes au contenu dynamique : parfois, les données que vous devez extraire ne se trouvent pas dans le HTML brut que vous avez obtenu après avoir effectué une requête HTTP. Elles peuvent être générées de manière dynamique (en utilisant AJAX et JavaScript). Selenium Python permet l'extraction de données même qui sont générées dynamiquement.
- Selenium Python est capable de faire des captures d'écran de la page que vous scraper.



2. Documentation du Selenium sous Python

Selenium Python sous Windows

Si vous utilisez Windows, vous pouvez effectuer les étapes suivantes :

Etape #1: installer Python

Tout d'abord nous allons installer python sur votre ordinateur. Cliquez sur le lien pour télécharger et installer python.

Etape #2: installer Selenium WebDriver

Ensuite, installez Selenium WebDriver à l'aide de Pip, qui est le gestionnaire officiel de package de python.

Ouvrez votre invite de commande et saisissez le code :

pip install selenium

Etape #3 : intégrer Selenium python avec un navigateur

Après l'installation, il faut que vous téléchargiez un pilote qui s'intègre au navigateur de votre choix. Ce pilote permettra à Selenium de contrôler le navigateur et d'automatiser les commandes que vous écrivez dans vos scripts. Ici on va utiliser le pilote de chrome.



Après le téléchargement, vous devez dézipper le fichier et placer l'exécutable sur votre stockage à un endroit de votre choix.

Après cela, copiez le chemin vers l'exécutable que vous ajoutez à votre variable d'environnement.

Etape #4 : vérifier les installations

Ensuite, vous pouvez effectuer un test dans votre invite de commande pour vérifier. Comme nous avions utilisé chrome, dans l'invite de commande

Administrateur: Invite de commandes - chromedriver

D:\>chromedriver
Starting ChromeDriver 94.0.4606.41 (333e85df3c9b656b518b5f1add5ff246365b6c24-refs/branch-heads/4606@{#845}) on port 9515
Only local connections are allowed.
Please see https://chromedriver.chromium.org/security-considerations for suggestions on keeping ChromeDriver safe.
ChromeDriver was started successfully.

Etape #5 : installer Visual Studio code (par exemple)

Après cela, vous pouvez installer Visual Studio Code.

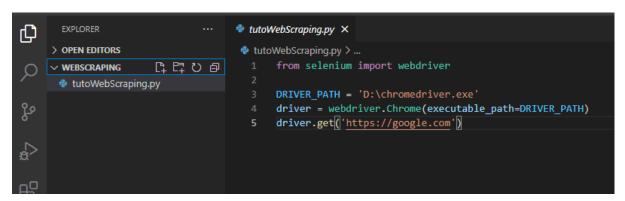
Etape #6 : créer un projet

Pour scrapper un site web avec Selenium Python, nous avons essentiellement 6 étapes à suivre :

- Trouver l'URL du site à scrapper ;
- Inspecter la page ;
- Trouver les données que nous voulons extraire ;
- Coder le script de scraping ;
- Exécuter le script et extraire les données ;

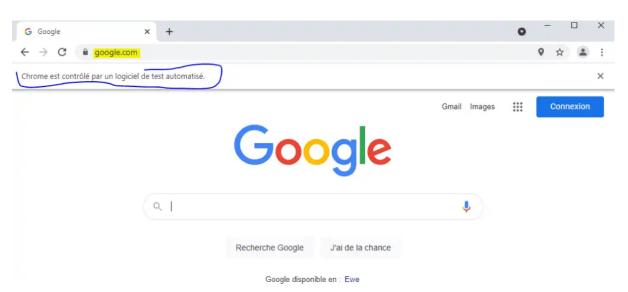


• Stocker les données sous le format requis.



La ligne 1 nous permet d'importer le WebDriver. Le chemin vers l'exécutable de chrome est visible à la ligne 3. Nous voyons par la suite, à la ligne 4 le code qui permet de lancer le navigateur. Enfin, on demande la page de google à la ligne 5.

Après lancement de ce bout de code, nous aurons le lancement du navigateur :



Vous devez voir un message indiquant que le navigateur est contrôlé par un logiciel automatisé.

Etape #7 : localiser un élément à scrapper



Maintenant, il faut que nous localisions l'élément que nous voulons scraper. Il existe de nombreuses méthodes disponibles dans l'API Selenium pour sélectionner des éléments sur la page. On peut utiliser :

- Nom de la balise
- Nom du site web
- ID
- XPath
- Sélecteurs CSS

Le moyen le plus simple de localiser un élément est d'ouvrir vos outils de développement Chrome et d'inspecter l'élément dont vous avez besoin.

Donc, après lancement du navigateur allez sur le de lws, par exemple.

Il existe de nombreuses façons de localiser un élément dans le sélénium. Disons que nous voulons localiser la balise title sur notre site web. Il suffit d'ajouter à notre précédent code ce bout de code :

7 title = driver.find_element_by_name('title')

Après exécution, nous pouvons voir dans notre console :



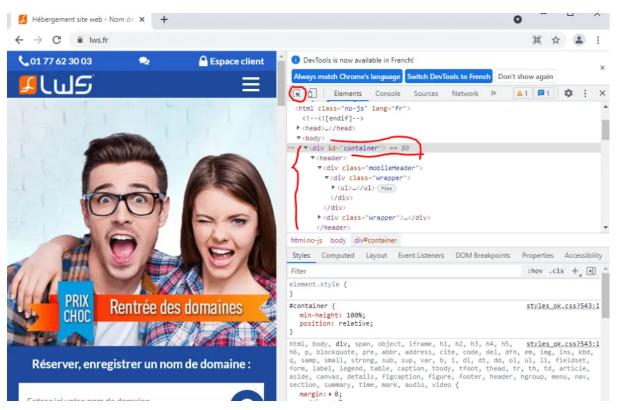
```
\remote\webdriver.py", line 496, in find_element_by_name
\remote\webdriver.py", line 976, in find_element
\remote\webdriver.py", line 321, in execute
\remote\errorhandler.py", line 242, in check_response

t: {"method":"css selector","selector":"[name="title"]"}
```

Etape #8 : extraire des données

Jusque-là, nous avons juste localisé un élément. Maintenant, supposons que nous voulons extraire certaines données de notre site web. On fera l'exemple avec le site lws

En premier lieu, nous allons visiter le site et inspecter l'élément que nous allons extraire.



Supposons que nous voulons l'information contenue dans la balise div dont l'id est container. Nous allons utiliser le





XPath dans cet exemple pour localiser notre élément. C'est un moyen puissant d'extraire n'importe quel élément d'une page, en fonction de sa position absolue sur le DOM ou par rapport à un autre élément.

```
tutoWebScraping2.py > ...

tutoWebScraping2.py > ...

from selenium import webdriver

DRIVER_PATH = 'D:\chromedriver.exe'

driver = webdriver.Chrome(executable_path=DRIVER_PATH)

driver.get('https://www.lws.fr/')

aPropos_details = []

aPropos_details = driver.find_elements_by_xpath('//*[@id="container"]')

for e in aPropos_details:

print(e.text)
```

Voici ce que fait notre code ci-dessus

De la ligne 3 à la ligne 5, nous l'avons expliqué plus haut. Ce qui a changé c'est juste le lien de la page visité (lws). Dans l'exemple précédent, c'était celui de google.

À la ligne 7 nous faisons une déclaration de tableau.

Ensuite, à la ligne 8, nous affectons les éléments de notre div grâce à la méthode find_elements_by_xpath de Sélénium en lui passant l'id de notre div. Les lignes suivantes, nous faisons juste un parcours du tableau pour afficher les données localisées.

Voici une partie des informations obtenues dans la console :



```
DevTools listening on ws://127.0.0.1:60414/devtools/browser/00a65a57-048c-4ffd-8bb3-73933b64c1b1
Hebergeur web, nom de domaine, serveur VPS et serveur dédié - LWS
Avis clients :
Mon panier :
0 article(s)
Tél : 01 77 62 30 03
Espace client
Contact
L'hébergement web accessible à tous
PLUS DE 280 000 SITES HÉBERGÉS
DOMAINE
HÉBERGEMENT
SERVEUR
EMAILS
```

```
DevTools listening on ws://127.0.0.1:60414/devtools/browser/00a65a57-048c-4ffd-8bb3-73933b64c1b1
Hebergeur web, nom de domaine, serveur VPS et serveur dédié - LWS
Avis clients :
Mon panier :
0 article(s)
Tél : 01 77 62 30 03
Espace client
Contact
L'hébergement web accessible à tous
PLUS DE 280 000 SITES HÉBERGÉS
DOMAINE
HÉBERGEMENT
SERVEUR
EMAILS
```

Tout ce qui est texte sur notre page web contenu dans notre div est affiché dans la console.



Démo sur les Scripts



"InfluencerList.ipynb" c'est script pour scraping d'un site web en utilisant selenium pour extraire Top 1000 username des plus gros influenceurs Instagram au monde.





```
#specify the path to chromedriver.exe (download and save on your computer)

driver = webdriver.Chrome('chromedriver.exe')
login_url='https://starngage.com/plus/en-us/login'
url='https://starngage.com/plus/en-us/influencer/ranking'
#open the webpage
driver.get(login_url)

email = WebDriverWait(driver, 10).until(EC.element_to_be_clickable((By.CSS_SELECTOR, "input[type='email']")))
password = WebDriverWait(driver, 10).until(EC.element_to_be_clickable((By.CSS_SELECTOR, "input[type='password']")))

in1=input("entrer ton email: ")
in2=input("entrer ton password: ")
email.clear()
email.send_keys(in1)
password.clear()
password.clear()
password.send_keys(in2)

button = WebDriverWait(driver, 2).until(EC.element_to_be_clickable((By.CSS_SELECTOR, "button[class='el-button rounded-pill btn-bl
```

```
names=[]
for k in range(10):
    try:
        url='https://starngage.com/plus/en-us/influencer/ranking?page='+str(k+1)
        driver.get(url)
        l=driver.find_elements(By.XPATH,('//a[@class="link color-pink text-break"]'))
        names=names+1
    except : pass
names=[k.text for k in names]
Python
```

```
print(len(names))

1000

print(names)

print(names)

username=pd.DataFrame(names,columns=['username'])

username.to_csv('username_scraped.csv')

Python
```

et voilà le résultat de ce script :



```
InfluencersList.ipynb
                      ■ username_scraped.csv ×
■ username_scraped.csv
       0,@cristiano
     1,@leomessi
     2,@kyliejenner
     3,@selenagomez
     4,@therock
      5,@arianagrande
      6,@kimkardashian
       7,@beyonce
     8,@khloekardashian
  11 9,@justinbieber
  12 10,@kendalljenner
  13 11,@taylorswift
  14 12,@jlo
      13,@virat.kohli
       14,@kourtneykardash
       15,@nickiminaj
      16,@neymarjr
      17,@mileycyrus
  20 18,@katyperry
```

Maintenant on passe au Script principal du Web Scraping avec Selenium sur la plateforme Instagram :

```
▷ ~ □ …
instagram.py
instagram.py > ...
      import undetected chromedriver as uc
      from selenium import webdriver
       from \ webdriver\_manager.chrome \ import \ ChromeDriverManager
       from selenium.webdriver.common.by import By
       import time
       import pandas as pd
       if __name__=='__main__':
           browser=uc.Chrome()
           browser.maximize_window()
           time.sleep(3)### waiting for three seconds
           profiles=pd.read_csv('username_scraped.csv')#loading profiles already scraped
           profiles=list(profiles["username"].astype("str"))
liste=map(lambda x: x.replace("@",""),profiles)
           prf=list(liste)
```



```
## Loading the Data in a csv file
with open('instagram_scrapping.csv', 'a') as myFile:
    myFile.write(name +","+username+","+number_following+","+number_followers+","+number_publi+"\n")
except:
    pass
```

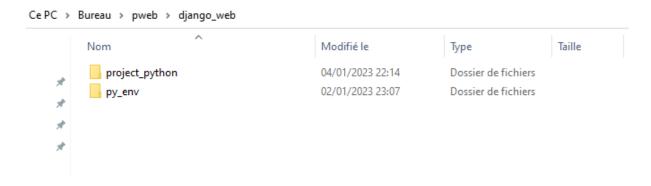
et voilà le résultat :

```
instagram_scrapping.csv ×
instagram_scrapping.csv
        name,username,Following,Followers,Posts
        Cristiano Ronaldo, cristiano, 533, 567M, "3, 416"
        Leo Messi, leomessi, 294, 447M, 980
        Kylie ♥,kyliejenner,96,407M,"7,035"
        Selena Gomez, selenagomez, 236, 400M, "1,869"
        Dwayne Johnson, therock, 641, 384M, "7,055"
        Ariana Grande, arianagrande, 605, 371M, "4, 988"
        Kim Kardashian, kimkardashian, 217, 363M, "5, 768"
        Beyoncé, beyonce, 0, 312M, "2, 054"
        Khloé Kardashian, khloekardashian, 111, 317M, "4, 205"
        Justin Bieber, justinbieber, 740, 296M, "7, 400"
   11
        Kendall, kendalljenner, 237, 291M, 642
        Taylor Swift, taylorswift, 0, 256M, 563
        Jennifer Lopez, jlo, "1,494", 245M, 220
        Virat Kohli, virat.kohli, 269, 244M, "1,491"
        Barbie, nickiminaj, 671, 221M, "6, 451'
        Kourtney Kardashian Barker, kourtneykardash, 147, 227M, "4, 433"
        NJ BR,neymarjr,"1,747",207M,"5,402"
        Miley Cyrus, mileycyrus, 317, 206M, "1, 202"
        KATY PERRY, katyperry, 754, 198M, "2, 104"
        Zendaya, "1,800", 174M, "3,536"
        Kevin Hart, kevinhart4real, 971, 173M, "8, 480"
```

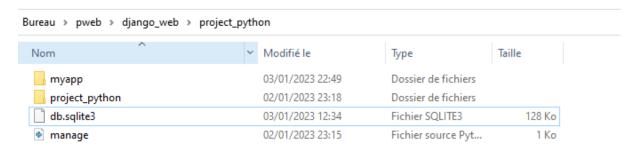


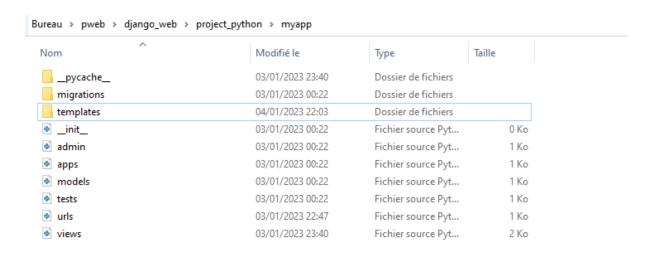
2. Implémentation web : django

On a créé tout d'abord un environnement virtuel : "py_env" et aussi le projet django sous le nom "project_python"



et voilà notre application sous le nom "myapp"







```
💠 urls.py 🔸 🗘 views.py 🔸
  1 from django.shortcuts import render
      import pandas as pd
      from django.contrib.auth.models import User
      from django.core.paginator import Paginator, EmptyPage, PageNotAnInteger
         df=pd.read_csv("C:/Users/user/Desktop/pweb/django_web/project_python/myapp/templates/instagram_scrapping.csv")
         df.dropna(inplace=True)
         json_records = df.to_json(orient ='records')
          data = json.loads(json_records)
          page = request.GET.get('page', 1)
          paginator = Paginator(data, 90)
              data = paginator.page(page)
          except PageNotAnInteger:
             data = paginator.page(1)
          except EmptyPage:
          data = paginator.page(paginator.num_pages)
context = {'d': data}
          return render(request, "table.html", context)
```

Bureau > pweb > django_web > project_python > project_python

Nom	Modifié le	Туре	Taille
pycache	03/01/2023 22:51	Dossier de fichiers	
init_	02/01/2023 23:15	Fichier source Pyt	0 Ko
🍨 asgi	02/01/2023 23:15	Fichier source Pyt	1 Ko
settings s	03/01/2023 22:19	Fichier source Pyt	4 Ko
• urls	03/01/2023 22:51	Fichier source Pyt	2 Ko
• wsgi	02/01/2023 23:15	Fichier source Pyt	1 Ko





```
urls.py
django_web > project_python > project_python > 💠 urls.py > ...
       from django.contrib import admin
       from django.urls import path, include
 17
 19
 20
       #dans localhost:8000
 21
       #directory here = project_python <=> localhost:8000
 22
       urlpatterns = [
           path('admin/', admin.site.urls),
 23
           path('', include('myapp.urls')),
 25
```



```
        Color of the color
```

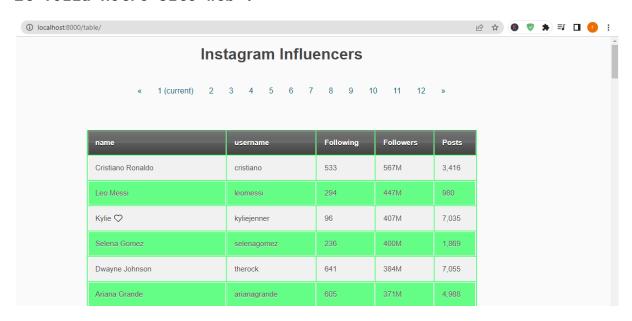
```
{% if d %}
         {% for i in d %}
              {{i.name}}
              {{i.username}}
              {{i.Following}}
              {{i.Followers}}
              {{i.Posts}}
        {% endfor %}
       {% endif %}
       {% if d.has_other_pages %}
<center>
 {% if d.has_previous %}
   <a href="?page={{ d.previous_page_number }}">&laquo;</a>
 {% else %}
   <a class="disabled"><span>&laquo;</span></a>
 {% endif %}
 {% for i in d.paginator.page_range %}
   {% if d.number == i %}
     <a class="active"><span>{{ i }} <span class="sr-only">(current)</span></span></a>
   {% else %}
     <a href="?page={{ i }}">{{ }i }}</a>
   {% endif %}
```







Et voila notre site web :



« 1 2 3 4	5 6 (current) 7 8	9 10	11 12	»
name	username	Following	Followers	Posts
Bretman (Da Baddest) Rock	bretmanrock	328	19M	1,793
Sidharth Malhotra	sidmalhotra	201	23M	1,150
Auron	auronplay	343	19M	802
LaTripleT	tinistoessel	974	21M	2,919
مصطنی حسنی Mustafa Hosny	mustafahosnyofficial	12	20M	10K
Álvaro Morata	alvaromorata	2,073	20M	1,376